

Московский Государственный Университет имени М.В.Ломоносова

Факультет Вычислительной Математики и Кибернетики

Кафедра Автоматизации Систем Вычислительных Комплексов

Лаборатория Компьютерной Графики и Мультимедиа

Введение в дипломную работу

**Автоматическое выделение объектов
в данных лазерного сканирования**

Роман Викторович Шаповалов, гр.522

Научный руководитель к.ф.-м.н., н.с.Антон Сергеевич Конушин

Москва, 2009

Московский Государственный Университет имени М.В.Ломоносова

Виза научного руководителя

Введение в дипломную работу студента

Романа Шаповалова

было прочитано и одобрено

Дата

Антон Сергеевич Конушин, Научный руководи-
тель

Аннотация

Автоматическое выделение объектов

в данных лазерного сканирования

Роман Викторович Шаповалов

В этой работе мы улучшили то, что нельзя было улучшить.

Abstract

Automatic object detection

in laser scans

Roman V. Shapovalov

In this paper we revisit main principles and the technological basis of the Rooter algorithm. We report significant growth of both efficiency and effectiveness.

Благодарности

I would like to thank the Academy...

Глава 1

Введение

1.1 Распознавание объектов в компьютерном зрении

Задача выделения объектов в данных, получаемых с помощью различного рода сенсоров, возникает очень часто. Например, в медицинских исследованиях требуется выделить определенные органы, опухоли или ткани организма на рентгеновских снимках или результатах томографии (рис. 1.1,а). В процессе биологических или фармакологических исследований часто возникают задачи, в которых требуется выделить на изображении, полученном с микроскопа, отдельные клетки или их части (рис. 1.1,в). В дефектоскопии тоже возникают подобные задачи, например, автоматизированный анализ качества продукции на конвейере или выделение дефектов дорожного покрытия [Barinova , 2009]. Ручное выделение объектов требует кропотливой и длительной работы эксперта, и поэтому эти задачи обычно автоматизируют с использованием методов компьютерного зрения.

С начала 90-х годов XX века учёные стали активно работать над проблемой анализа данных лазерного сканирования, которые представляют собой так на-




Рис. 1.1: Примеры задач выделения объектов определенных классов на изображениях: (а) – медицинские изображения, выделение печени; (б) – аэрофотоснимки, выделение полей различных культур; (в) – биологические изображения, выделение клеток различных типов

зываемые облака точек, хотя первые работы на эту тему появились ещё в 80-х годах [Horn, 1984]. Интуитивно, анализ трёхмерных данных выглядит более простой задачей, чем анализ изображений, поскольку последний фактически представляет собой обратную задачу: при получении фотографии значительная часть информации о пространственной структуре сцены теряется. Высокий потенциал трёхмерного представления данных отмечал ещё один из пионеров компьютерного зрения, David Marr, который считал, что даже распознавание объектов на двумерных изображениях должно выполняться посредством восстановления поверхностей трёхмерного пространства, идентифицирующих объекты. Однако на практике ситуация с лазерными сканами не такая оптимистичная: часто они похожи скорее на карты глубины, чем на аппроксимацию трёхмерной формы объекта. Даже если объект снят с нескольких ракурсов (разработаны методы эффективной регистрации облаков точек [Велижев, 2008]), он может быть заго-

рожен другими объектами или сам собой, если он невыпуклый, поэтому скан может содержать не полную поверхность объекта. Данные лазерного сканирования часто бывают зашумлены и разрежены. Они не обладают привычной цветовой информацией. К тому же, обработка облаков точек человеком с помощью существующих технических средств затруднена, так как они ориентированы прежде всего на вывод и ввод двумерных данных.


Тем не менее, анализ трёхмерных данных зачастую полезен. Например, данные с лазерных сенсоров незаменимы для навигации мобильных роботов. Лазерная съёмка применяется также для создания моделей зданий в архитектуре, для обработки данных аэрофотосъёмки в геодезии, для контроля качества продукции, а также для сохранения культурного и исторического наследия. В отличие от фотографий, результат сканирования незначительно зависит от погодных условий. Данные более "объективны" в том смысле, что охватывается большая часть пространства. Например, для обучения мобильного робота требуются фотографии с определённого ракурса, поскольку камеры, как правило, располагаются на определённой высоте. Размеченные данные для одной модели робота неэффективно использовать для другой. Высококачественная точечная модель в свою очередь задаёт положение объекта в абсолютных координатах, поэтому универсальна для всех моделей роботов [Lai Fox, 2009].

1.2 Технология лазерного сканирования

Технология лазерной съёмки аналогична технологии радиолокации, но, в отличие от радаров, лазерные сканеры испускают более короткие волны электромагнитного спектра: инфракрасные, видимые или ультрафиолетовые. Сканер (рис. 1.2а) испускает световые импульсы и замеряет время возврата отражённого от



(а) Фотография стационарного лазерного сканера




(b) Типичный пример облака точек: Stanford Bunny

Рис. 1.2: Технология лазерного сканирования

объекта сигнала (иногда также его интенсивность). Таким образом, в результате сканирования получается *облако точек*: неупорядоченный набор точек трёхмерного пространства (рис. 1.2b). Имея данные о положении и ориентации сканера, можно перевести облако точек в абсолютные координаты. Если имеются несколько сканов одной сцены из разных точек обзора, они могут быть сшиты в одно облако точек (если сканы представлены в абсолютных координатах, задача становится тривиальной). Таким образом, сканируя сцену с разных позиций, можно получить достаточно полную информацию о её пространственной структуре.

В этой работе нас прежде всего интересуют сканы естественных сцен (в противоположность сканам одного объекта). Можно выделить несколько классов таких сканов:



(a) Скан, полученный с помощью стационарного сканера. [Lai Fox, 2009] Цвета отражают классы объектов: бирюзовый — уровень земли, синий — транспорт, жёлтый — дорожные знаки, фиолетовый — люди, красный — здания, серый — другое

(b) Скан, полученный с движущегося автомобиля [Munoz, 2008]. Цвета отражают классы объектов: малиновый — здания, оранжевый — дорога, зелёный — деревья, синий — столбы, голубой — тротуар

Рис. 1.3: Примеры сканов наружных сцен.

- сканы, снятые со стационарного сканера (рис. 1.3a). Если это скан городской сцены, то в них можно выделять здания, людей, транспортные средства, столбы, ЛЭП
- сканы, снятые с движущегося по дороге сканера (рис. 1.3b). Классы объектов примерно такие же, как в предыдущем случае.
- сканы, снятые с самолёта. Такие сканы характеризуются более низким разрешением и отсутствием информации о вертикальных поверхностях (обычно присутствуют только крыши зданий, о стенах информация недостаточна). Поскольку такие сканы применяются для задач картографии и паспортизации, имеет смысл искать здания, деревья (лес), дороги, водоёмы и пр.

Глава 2

Постановка задачи

2.1 Формальная постановка задачи

Мы поставили задачу реализовать алгоритм машинного обучения для классификации точек скана. Решается задача выделения объектов в скане и их категоризация. Это значит, что конкретный класс описывает все объекты типа X , но не конкретные их экземпляры. Например, к одному классу относятся все автомобили, к другому - все здания и т.д.

На *вход* алгоритму машинного обучения поступает размеченное облако точек, то есть множество векторов вида (x, y, z, c) , первые три компоненты которых задают координаты точек в трёхмерном метрическом пространстве \mathbb{R}^3 , а последняя — метку класса для объекта, которому принадлежит точка, которая выбирается из предопределённого неупорядоченного конечного множества классов. На *выходе* алгоритм машинного обучения должен предоставить другой алгоритм — классификатор (который предполагается искать в параметрическом семействе алгоритмов), который на вход получает неразмеченное облако точек, и для каждой его точки находит метку класса. Итак, классификатор реализует функцию

со следующей сигнатурой:

$$A : ((x_1, y_1, z_1), (x_2, y_2, z_2), \dots, (x_n, y_n, z_n)) \mapsto (c_1, c_2, \dots, c_n), c_i \in \{1, \dots, K\}$$

Необходимо заметить, что облака точек должны быть достаточно велики (n велико) и хотя бы кусочно-непрерывны (при аппроксимации поверхностью), поскольку для каждой точки должна найтись окрестность. Это следует из того, что сама по себе точка в трёхмерном пространстве не несёт никакой информации, она важна лишь в контексте поверхности, которую она образует.

2.2 Критерии качества

Как и в любой задаче машинного обучения, здесь можно определить формальные критерии качества на основе минимизации эмпирического риска. Необходимо собрать достаточно большое количество размеченных облаков точек одного типа. Разделив имеющиеся облака на обучающую и тестовую выборки, можно оценить качество алгоритма обучения. Обучившись на обучающей выборке, мы получаем алгоритм классификации. Подав ему на вход тестовую выборку, мы получим результаты классификации. Поскольку мы знаем ожидаемый результат классификации, мы можем вычислить *точность* — часть правильно классифицированных точек. Это и есть функционал, который мы будем стараться максимизировать.

Чтобы избежать проблемы переобучения, будем использовать технику скользящего контроля (кросс-валидации). В этом случае все доступные размеченные сканы делятся на n частей примерно равного размера, и производится n сеансов обучения и тестирования. На каждом из них из выборки выкидывается одна из частей, которая используется для теста, остальные — для обучения. На сегодняшний день техника скользящего контроля — самый надёжный способ тестирования алгоритмов машинного обучения.

2.3 Цели работы

Мы поставили перед собой следующие цели:

- Составить обзор методов классификации облаков точек
- Собрать выборку размеченных лазерных сканов различных типов для тестирования алгоритмов
- Разработать алгоритм обучения классификатора, показывающий точность, сопоставимую с точностью современных методов на сканах различных типов
- Разработать алгоритм, точность которого на сканах, снятых с перемещающихся по дороге транспортных средств, будет превосходить точность других методов

Глава 3

Обзор существующих методов

Как правило, системы распознавания объектов строятся по следующей схеме:

- предобработка
- подсчёт признаков
- обучение/классификация

Рассмотрим отдельно, какие признаки извлекаются для специфичных данных лазерного сканирования, и какие алгоритмы машинного обучения используются.

3.1 Предобработка

На стадии предобработки облака точек унифицируются и подготавливаются к дальнейшей обработке. К облаку может быть применён некоторый фильтр, например, сглаживающий шумы. Для больших облаков точек также важно строить индекс, который позволяет оптимизировать процесс поиска точки в трёхмерном пространстве. Для этого могут использоваться kd-деревья, октодеревья, R-деревья и их всевозможные модификации.

3.2 Признаки облаков точек

Выбор признаков является решающим фактором качества классификации. Признаки считаются либо для групп точек (сегментов), либо для отдельных точек. В последнем случае для подсчёта признаков используется некоторая окрестность точки — обычно берутся все точки в фиксированном радиусе, чтобы признаки не зависели от плотности сканирования. В статьях различных авторов используются разные наборы признаков. Как правило, они специфичны для конкретной задачи, но некоторые принципы выделить можно. Как правило, признаки должны быть инвариантны к плотности сканирования и к повороту (иногда за исключением вертикальных поворотов). Многие авторы используют аппроксимацию окрестности точки плоскостью, что понятно, поскольку скан обычно представляет собой достаточно гладкую поверхность.

3.2.1 Спин-изображения

Определение

В статье [Johnson Hebert, 1999] вводится определение спин-изображений, которые часто используются для подсчёта локальных признаков. Для некоторой точки, для которой задана нормаль и набор соседних точек, можно вычислить такое изображение. Фактически, это вид из точки на другие точки окрестности, усреднённый вращением вокруг нормали и смазанный билинейным фильтром. Чем больше точек видно под конкретным углом, тем темнее будет в этом месте изображение. Более подробно: для точки O задаётся система координат $\alpha\beta$, где α — расстояние от точки до нормальной прямой к O , а β — направленное расстояние от точки до касательной плоскости в O . Таким образом, точки на окружности с центром на нормальной прямой в O и перпендикулярные ей, проектируются

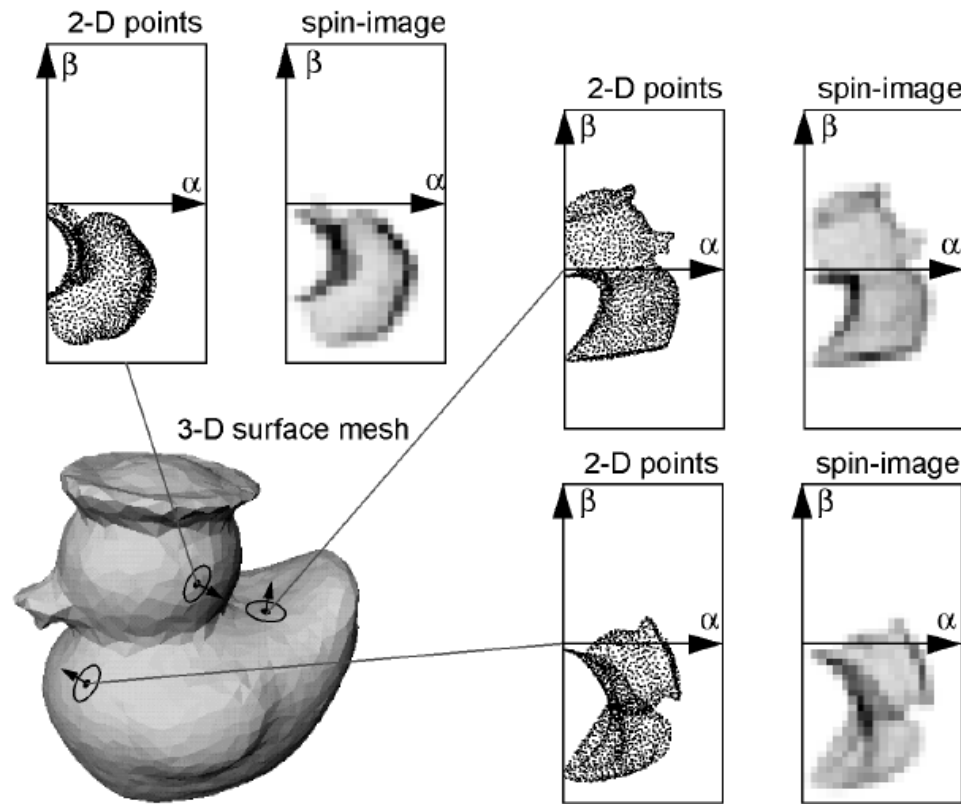


Рис. 3.1: Иллюстрация к определению спин-изображения. [Johnson Hebert, 1999]

в одну точку пространства $\alpha\beta$. (рис. 3.1) Спин-изображения часто используются для сопоставления поверхностей, так как разные сканы одной поверхности должны иметь похожие (хотя и не совпадающие точно) спин-изображения.

Применение

В статье [Angelov , 2005] авторы предложили использовать спин-изображения для мелких объектов типа каркасных кукол (в противоположность городским сценам) как признаки, инвариантные к любым поворотам. Предполагается для точек считать спин-изображения [Johnson Hebert, 1999], квантуя пространство $\alpha\beta$ на 5×10 частей. Считается несколько изображений разного масштаба, произ-




Рис. 3.2: Иллюстрация к варианту спин-изображения от Endres.[Endres , 2009]

водится анализ главных компонент и берутся значения 45 главных компонент. Интересна проблема выбора размера изображений. Согласно выводам авторов статьи, он должен быть сопоставим с размером мелких деталей объектов (например, головы куклы).

Статья [Triebl , 2007] является продолжением разработок статьи [Anguelov , 2005]. Авторы также предлагают считать спин-изображения 5x10 в сферах радиуса 10 и 15 сантиметров.

Модификации

Endres и др. [Endres , 2009] предлагают считать признаки по авторскому варианту спин-изображений. Для точки вычисляется нормаль с помощью анализа главных компонент по окрестности радиусом 10 см. Как и в обычных спин-изображениях, объект вращается вокруг нормали в исходной точке, но бины изображения собирают не просто точки, а средние значения углового расстояния от нормалей в точках до нормали к исходной точке (рис. 3.2). Авторы показали, что их вариант даёт результаты лучше, чем классический метод при распознавании абстрактных категорий объектов (таких как "человек" "ящик").

3.2.2 Признаки матрицы ковариаций

Munoz и др. [Munoz , 2008] [Munoz , 2009] используют спектральный подход. Считаются следующие признаки:

- спектральные признаки: производится анализ главных компонент в некоторой локальной окрестности точки (авторы брали все точки в радиусе 60 см), пусть $\lambda_0, \lambda_1, \lambda_2$ – собственные значения матрицы ковариаций в порядке неубывания. Тогда $\sigma_p = \lambda_0$, $\sigma_s = \lambda_1 - \lambda_0$, $\sigma_l = \lambda_2 - \lambda_1$ – признаки, отвечающие за сходство распределения с точкой, поверхностью или линией соответственно. Подход напоминает технику выделения границ и углов на изображениях с помощью соответствующих фильтров (таких как Canny[Canny, 1986] и Harris[Harris Stephens, 1988]).
- признаки направления: ищутся касательный вектор ν_t и вектор нормали ν_n в точке как собственные векторы (наименьшая и главная компоненты соответственно). Далее считаются синусы и косинусы углов, образованных этими векторами с вертикальной и горизонтальной плоскостями
- признаки сходства: ν_t и ν_n нормируются на $\sigma_l / \max_{i \in \{p,l,s\}} \sigma_i$ и на $\sigma_n / \max_{i \in \{p,l,s\}} \sigma_i$ соответственно. Сходство двух признаков f_1 и f_2 вводится как $1/(1+|f_1-f_2|)$

3.2.3 Признаки, специфичные для области

Городские сцены

Для городских сцен авторы [Anguelov , 2005] рекомендуют использовать признаки, инвариантные к повороту в плоскости XU , а также инвариантные к плотности сканирования:

- Вокруг точки описывается куб со стороной 1 метр (точка - в центре), берутся все его точки. Далее выполняется анализ главных компонент и по двум компонентам строится плоскость (назовём её *принципиальной*). Далее куб делится на 27 подкубов, которые ориентированы в соответствии с принципиальной плоскостью, и считается количество точек в каждом подкубе. Таким образом очень хорошо искать "сгустки- точек и плоскости (оценивать планарность окрестности точки).
- Вокруг точки строится вертикальный цилиндр радиуса 25 см. Вычисляются проценты точек в различных сегментах цилиндра (например, лежащие между плоскостями $z = 2.0$ и $z = 2.5$ метров). $z \approx 0$, как правило, соответствует классу поверхности земли.
- Бинарный признак ($z < 2.0$ метров) позволяет отсеивать кустарники.

Выделение окон

Статья [Triebel , 2006] является продолжением разработок [Anguelov , 2005]. Они пытались выделять окна на стене, поэтому они сначала выделяли стену как основную плоскость, а затем уже считали следующие признаки, зная её положение:

- распределение (гистограмма) косинусов углов между нормалью к стене и нормальями к точкам в окрестности
- отклонение высоты точки от плоскости стены
- нормализованная высота (нормировка на 15 метров)




Рис. 3.3: Иллюстрация к статье [Brostow , 2008]. Показаны три из пяти используемых типов признаков.

Навигация автотранспорта

[Brostow , 2008] используют довольно оригинальный набор признаков, специфичных для навигации автомобилей. Хотя авторы используют для распознавания плотное стерео вместо облаков точек, признаки заслуживают внимания. Они выбирались так, чтобы они были робастными, интуитивными, эффективно вычислимыми и универсальными (по отношению к категориям объектов). Авторы также считают этот набор избыточным:

- высота над уровнем камеры f_H : высота – единственная из координат, которая сама по себе несёт некоторый смысл. Из неё вычитают калиброванную высоту расположения камеры, чтобы данные были инвариантны относительно расположения камеры на автомобиле и автомобиля (рис. 3.3)
- длина перпендикуляра на траекторию f_C : хотя камера может проехать по разным траекториям, это признак имеет смысл: деревья и здания обычно удалены от дороги. Проблема в том, что иногда точка не может быть видна

(сканирована) в момент её ближайшего расстояния – например, точки на поверхности дороги загорожены самой машиной (рис. 3.3)

- ориентация поверхности f_{O_x} , f_{O_y} : выполняется двумерная триангуляция Делоне на плоскости изображения, затем треугольники восстанавливаются обратно, считаются их нормали и берутся их проекции снова на двумерное пространство изображения. Проекция нормали задаётся в нём двумя координатами
- плотность траектории f_D : количество точек, проецируемых в плоскость изображения. Разные объекты могут обладать различной степенью "текстурированности": деревья и здания более плотные, чем небо и дорога, а автомобили могут быть в разных местах плотными (кузов) и неплотными (стёкла).
- невязка репроекции f_R : необходимо отслеживать объект на плоскости изображения и смотреть, как "смещается" облако, его представляющее. Таким образом можно отследить пешеходов и подвижный транспорт. (рис. 3.3)

3.3 Методы классификации

3.3.1 Независимая классификация точек

Самый простой вариант классификации – считать функции назначения меток класса отдельным точкам независимыми одинаково-распределёнными случайными величинами. Методы восстановления зависимостей такого рода хорошо проработаны в машинном обучении: это алгоритмы обучения классификатора, такие как индукция решающих деревьев [Breiman, 1984], бустинг [Freund, Schapire, 1999],

метод опорных векторов (SVM) [Drucker , 1996]. Однако на практике обычно учитывают зависимость между соседними точками, поскольку это позволяет повысить робастность метода классификации. Благодаря выбору окрестности точки происходит локальное сглаживание выхода классификатора, но имеет смысл также использовать методы глобальной оптимизации.

3.3.2 Совместная классификация точек

Для моделирования назначения меток классов обычно используются Марковские сети. Марковской сетью называется графическая вероятностная модель, в которой связанные случайные переменные представляют собой зависимые стохастические процессы. В контексте облаков точек в Марковскую сеть объединяются точки облака, а значением случайной величины в узле сети является метка класса, соответствующая точке [Angelov , 2005]. Интерес представляет способ задания энергии Марковской сети, которую должен максимизировать алгоритм классификации.

Более строго, для задачи классификации точек вводится следующая Марковская сеть. Имеем набор дискретных случайных величин $\mathbf{Y} = \{Y_1, \dots, Y_n\}$, каждая из которых представляет одну точку скана и принимает значения из $Y_i \in \{1, \dots, K\}$, которые представляют метки классов, назначаемые точкам. Таким образом, вероятность назначения точкам соответствующих меток $\mathbf{y} = \{y_1, \dots, y_n\}$ задаётся совместным распределением $\mathbf{P}(\mathbf{Y} = \mathbf{y}) = \mathbf{P}(Y_1 = y_1, \dots, Y_n = y_n)$. Зависимость между случайными величинами задаётся неориентированным графом, в котором вершины соединяются ребром, если соответствующие точки облака находятся поблизости в соответствии с некоторой метрикой (например, евклидово расстояние между точками меньше установленного порога).

В общем случае, для осуществления вывода в Марковских сетях нужно учи-

тывать потенциалы всех полных подграфов, которые задают вероятность назначения на них. Несмотря на это, обычно рассматривают только унарные потенциалы (потенциалы вершин) $\phi_i(Y_i)$ и парные потенциалы (потенциалы рёбер) $\phi_{ij}(Y_i, Y_j)$ - заданные неотрицательные функции. В этом случае можно осуществлять эффективный вывод, но сохраняется достаточная достоверность модели. Совместное распределение случайных переменных в модели записывается следующим образом:

$$\mathbf{P}(\mathbf{Y} = \mathbf{y}) = \frac{1}{Z} \prod_{i=1}^n \phi_i(y_i) \prod_{i=1}^n \prod_{j=1}^n \phi_{ij}(y_i, y_j)$$

, где Z - нормировка (статистическая сумма), не зависящая от \mathbf{y}

Необходимо с помощью выбора назначения максимизировать правдоподобие модели. Учитывая свойства монотонности логарифма, в задаче оптимизации можно перейти к максимизации суммы логарифмов:

$$\sum_{i=1}^n \log(\phi_i(y_i)) + \sum_{i=1}^n \sum_{j=1}^n \log(\phi_{ij}(y_i, y_j)) - \log Z \rightarrow \max_{\mathbf{y}}$$

Последний член константный, поэтому его можно исключить из формулировки максимизируемой энергии. В задачах компьютерного зрения чаще всего используется обобщение модели Поттса выбора потенциалов, которая приводит нас к случаю *ассоциативной Марковской сети*: $\log \phi_{ij}(k, k) = \lambda_{ij}^k \geq 0, \log \phi_{ij}(k, l) = 0, k \neq l$. В ассоциативных Марковских сетях возможен вывод с помощью алгоритмов разрезов графа [Kolmogorov Zabih, 2004].

На практике потенциалы обычно назначаются как функции от признаков. Пусть мы имеем наборы признаков $\mathbf{x}_i \in \mathbb{R}^{d_n}$ для вершин и $\mathbf{x}_{ij} \in \mathbb{R}^{d_e}$ для рёбер. Для облаков точек признаки вершин подробно описаны в предыдущей подсекции. Признаки рёбер можно задавать как расстояние между точками, угол между их приближёнными нормальными, но на практике часто парный потенциал определяют константным, поэтому признаки вычислять не требуется [?].

Для регрессии признаков к потенциалам часто используется линейная модель: $\log(\phi_i(k)) = w_n^k \cdot \mathbf{x}_i$, $\log(\phi_{ij}(k, k)) = w_e^k \cdot \mathbf{x}_{ij}$. Учитывая ограничения, задаваемые ассоциативной Марковской сетью, удобно полагать, что веса и признаки - неотрицательные величины.

В случае классификации на два класса минимум функции энергии эффективно находится с помощью алгоритмов поиска минимального разреза в графе. Если же классов больше двух, то задача становится NP-трудной, но был предложен приближённый алгоритм альфа-расширения [Boykov , 1998], который находит решение не более чем в 2 раза худшее оптимального. Другой подход - сформулировать эту задачу как задачу целочисленного программирования. Она решается ослаблением ограничений, и решается задача линейного программирования. На практике решение задачи линейного программирования работает дольше, чем поиск минимального разреза на графе [Taskar , 2004].

Литература

[Anguelov , 2005] Anguelov D., Taskar B., Chatalbashev V., Koller D., Gupta D., Heitz G., Ng A., Discriminative learning of markov random fields for segmentation of 3d range data. *IEEE Conf. on Computer Vision and Pattern Recognition (CVPR)* . 2005. 169–176, URL [PDF] (<http://www.seas.upenn.edu/~taskar/pubs/cvpr05.pdf>).

[Barinova , 2009] Barinova O., Shapovalov R., Sudakov S., Velizhev A., Konushin A., Efficient road mapping via interactive image segmentation. *3D City Models, Road Databases and Traffic Monitoring (CMRT)* . 2009. 38, 1–6, URL [PDF] (http://graphics.cs.msu.ru/sites/default/files/download/CMRT09_Barinova_et_al).

[Boykov , 1998] Boykov Y., Veksler O., Zabih R., Markov random fields with efficient approximations. *IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR)* . 1998. 648.

[Breiman , 1984] Breiman L., Friedman J.H., Olshen R.A., Stone C.J., *Classification and regression trees*. Monterey, CA: Wadsworth & Brooks/Cole Advanced Books & Software. 1984, ISBN 978-0412048418.

[Brostow , 2008] Brostow G.J., Shotton J., Fauqueur J., , Cipolla R., Segmentation and recognition using structure from motion point clouds. *ECCV* . 2008. URL [PDF] (<http://jamie.shotton.org/work/publications/eccv08.pdf>).

- [Canny, 1986] Canny J., A computational approach to edge detection. *IEEE Transactions on Pattern Analysis and Machine Intelligence, PAMI* . 1986. 8, 679–698.
- [Drucker , 1996] Drucker H., Burges C.J., Kaufman L., Smola A., Vapnik V., Support vector regression machines. *Neural Information Processing Systems (NIPS)* . 1996. 9, 155–161.
- [Endres , 2009] Endres F., Plagemann C., Stachniss C., Burgard W., Unsupervised discovery of object classes from range data using latent dirichlet allocation. *Robotics: Science and Systems (RSS)* . 2009. URL [PDF] (<http://www.informatik.uni-freiburg.de/~endres/files/msc/endres09rss.pdf>).
- [Freund Schapire, 1999] Freund Y., Schapire R., A short introduction to boosting. *Sixteenth International Joint Conference on Artificial Intelligence (IJCAI)* . 1999. 14, 1401–1406.
- [Harris Stephens, 1988] Harris C., Stephens M., A combined corner and edge detector. *Alvey Vision Conference* . 1988. 147–152.
- [Horn, 1984] Horn B., Extended gaussian images. *Proceedings of the IEEE* . 1984. 72, 1671–1686.
- [Johnson Hebert, 1999] Johnson A., Hebert M., Using spin images for efficient object recognition in cluttered 3d scenes. *IEEE PAMI* . 1999. 21, 433–449, URL [PDF] (<http://eprints.kfupm.edu.sa/74936/1/74936.pdf>).
- [Kolmogorov Zabih, 2004] Kolmogorov V., Zabih R., What energy functions can be minimized using graph cuts? *IEEE Transactions on Pattern Analysis and Machine Intelligence (PAMI)* . 2004. 26, 147–159, URL [PDF] (http://www.cs.ucl.ac.uk/staff/V.Kolmogorov/papers/KZ-PAMI-graph_cuts.pdf).

- [Lai Fox, 2009] Lai K., Fox D., Laser scan classification using web data and domain adaptation. *Robotics: Science and Systems (RSS)* . 2009. URL [PDF] (<http://www.roboticsproceedings.org/rss05/p22.pdf>).
- [Munoz , 2008] Munoz D., Vandapel N., Hebert M., Directional associative markov network for 3-d point cloud classification. *Fourth International Symposium on 3D Data Processing, Visualization and Transmission* . 2008. URL [PDF] (http://www.ri.cmu.edu/pub_files/pub4/munoz_daniel_2008_1/munoz_daniel_2008_1.pdf).
- [Munoz , 2009] Munoz D., Vandapel N., Hebert M., Onboard contextual classification of 3-d point clouds with learned high-order markov random fields. *ICRA* . 2009. URL [PDF] (http://www.ri.cmu.edu/pub_files/2009/5/munoz_icra_09.pdf).
- [Taskar , 2004] Taskar B., Chatalbashev V., Koller D., Learning associative markov networks. *Twenty-First International Conference on Machine Learning (ICML)* . 2004. URL [PDF] (<http://ai.stanford.edu/~koller/Papers/Taskar+al:ICML04.pdf>).
- [Triebel , 2006] Triebel R., Kersting K., Burgard W., Robust 3d scan point classification using associative markov networks. *ICRA* . 2006. URL [PDF] (<http://www.asl.ethz.ch/people/rtriebel/personal/publications/Triebel06Robust>).
- [Triebel , 2007] Triebel R., Mozas O.M., Burgard W., Collective classification for labeling of places and objects in 2d and 3d range data. *31th Annual Conference of the German Classification Society on Data Analysis, Machine Learning, and Applications* . 2007. URL [PDF] (<http://www.asl.ethz.ch/people/rtriebel/personal/publications/triebel07collect>).
- [Велижев, 2008] Велижев , Разработка и исследование алгоритмов автоматического взаимного ориентирования трехмерных дискретных моделей объектов,

полученных в результате лазерного сканирования : диссертация на соискание учёной степени кандидата технических наук. 2008.